Practica 1

Introducción a la Ciencia de Datos. Máster en Ciencia de Datos- UV

Pau Bover Femenias

2026-10-20

Índice

1. Practica 1 **1**
1.1. Ejercicio 2 . . . 1
1.1.1. 2.1 Importación del fichero . . . 1
1.1.2. 2.2 Inspección de los datos . . . 2
1.2. Ejercicio 3 . . . 3
1.2.1. 3.1 . . . 3
1.2.2. 3.2 . . . 4
1.3. Ejercicio 4 Fichero SPSS PsychBike.sav . . . 5
1.3.1. 4.1 . . . 5
1.3.2. 4.2 . . . 5
1.4. Ejercicio 5 Fichero data iris.zip . . . 7
1.4.1. 5.1 . . . 7
1.5. Ejercicio 6 . . . 7
1.5.1. 6.1 . . . 7
1.5.2. 6.2 . . . 8
1.6. Ejercicio 7 . . . 8
1.6.1. 7.2 . . . 8
1.6.2. 7.3 . . . 9
1.6.3. 8.2 . . . 13
1.6.4. 8.3 . . . 14

1. Practica 1

Pau Bover Femenias

1.1. Ejercicio 2

1.1.1. 2.1 Importación del fichero

1.1.1.1. 1 La unica diferencia que he apreciado es el formato en el que importa las horas, el base me las importa como char mientras que el readr las importa como hms (como horas) correctamnete por tando se pude ordenar por tiempo sino ordena por caracteres lo cual es incorrecto, ademas el base me ha detectado directmane el separador, mientras que el readr le he tenido que indicar que usase el tabulador como delimitador.

```
library(readr)

fname <- 'data/DFP1_11122015 124700.csv'
```

```
Deposito <- read.csv(
  file = fname,
  stringsAsFactors = FALSE,
  sep = "\t"
)
```

1.1.1.2. 2

```
Deposito$FECHA <- as.POSIXlt(
  Deposito$FECHA,
  format = "%d/%m/%Y",
  tz = "Europe/Madrid"
)

Deposito$HORA <- hms::as_hms(Deposito$HORA)

head(Deposito[c("FECHA", "HORA")])
```

1.1.1.3. 3

```
##        FECHA     HORA
## 1 2015-12-11 12:47:02
## 2 2015-12-11 12:47:02
## 3 2015-12-11 12:47:02
## 4 2015-12-11 12:47:03
## 5 2015-12-11 12:47:03
## 6 2015-12-11 12:47:03
```

```
save(
  Deposito,
  file = "./data/results/Deposito.RData"
)
```

1.1.1.4. 4

1.1.2. 2.2 Inspección de los datos

```
str(Deposito)
```

```
## 'data.frame':    8887 obs. of  5 variables:
##  $ FECHA            : POSIXlt, format: "2015-12-11" "2015-12-11" ...
##  $ HORA             : 'hms' num  12:47:02 12:47:02 12:47:02 12:47:03 ...
##   ..- attr(*, "units")= chr "secs"
##  $ Altura           : num  138 138 138 138 138 ...
##  $ Combinacion_Canya: num  2 2 2 2 2 2 2 2 2 2 ...
##  $ Temperatura      : num  14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 ...
```

```
head(Deposito)
```

```
##        FECHA     HORA Altura Combinacion_Canya Temperatura
## 1 2015-12-11 12:47:02 137.81                 2        14.6
## 2 2015-12-11 12:47:02 137.81                 2        14.6
## 3 2015-12-11 12:47:02 137.81                 2        14.6
```

```
## 4 2015-12-11 12:47:03 137.81                 2        14.6
## 5 2015-12-11 12:47:03 137.81                 2        14.6
## 6 2015-12-11 12:47:03 137.81                 2        14.6
```

```
tail(Deposito)
```

```
##           FECHA     HORA Altura Combinacion_Canya Temperatura
## 8882 2015-12-11 13:49:41 949.13                 2        14.7
## 8883 2015-12-11 13:49:41 949.13                 2        14.7
## 8884 2015-12-11 13:49:41 949.13                 2        14.7
## 8885 2015-12-11 13:49:41 949.13                 2        14.7
## 8886 2015-12-11 13:49:41 949.13                 2        14.7
## 8887 2015-12-11 13:49:42 949.13                 2        14.7
```

```
summary(Deposito)
```

```
##      FECHA                HORA              Altura       Combinacion_Canya
##  Min.   :2015-12-11   Length:8887        Min.   : 137.8   Min.   :1
##  1st Qu.:2015-12-11   Class1:hms         1st Qu.: 400.9   1st Qu.:1
##  Median :2015-12-11   Class2:difftime    Median : 953.1   Median :2
##  Mean   :2015-12-11   Mode  :numeric     Mean   : 785.8   Mean   :2
##  3rd Qu.:2015-12-11                      3rd Qu.:1079.0   3rd Qu.:3
##  Max.   :2015-12-11                      Max.   :1089.1   Max.   :3
##   Temperatura
##  Min.   :14.40
##  1st Qu.:14.50
##  Median :14.60
##  Mean   :14.57
##  3rd Qu.:14.60
##  Max.   :14.70
```

- str() lo imprime a texto como un resumen en la consola
- head() y tail() devulven las 5 primeras/ultmias filas del dataset como un nuevo dataset
- summary() devuvle un conjunto de estadisticos de los datos

1.2. Ejercicio 3

1.2.1. 3.1

1.2.1.1. 1 Lo cargo directamnte con readr no pide nada adicional: - **`Transaction`**: identificador de la compra, almacenado como numérico (`double`). Se repite cuando una compra incluye varios productos; no representa una cantidad. - **`Item`**: producto comprado. Es una variable cualitativa nominal, almacenada como texto (`character`). - **`date time`**: fecha y hora de la compra. Es una variable temporal, actualmente almacenada como texto; conviene convertirla a `POSIXct` o `POSIXlt`. - **`period day`**: franja del día de la compra, como mañana o tarde. Es una variable categórica con orden temporal, almacenada como texto (`character`). - **`weekday weekend`**: indica si la compra se realizó entre semana o en fin de semana. Es una variable cualitativa nominal binaria, almacenada como texto (`character`).

```
library(readr)

filename <- "data/bakery_sales_revised.csv"

BreadBasket <- read.csv(
  filename,
  stringsAsFactors = FALSE
```

```
)

#Arreglo el formato fecha
BreadBasket$date_time <- as.POSIXlt(
  BreadBasket$date_time,
  format = "%m/%d/%Y%H:%M",
  tz = "Europe/London"
)


save(
  Deposito,
  file = "./data/results/BreadBasket.RData"
)

head(BreadBasket)
```

1.2.1.2. 2

```
##   Transaction          Item           date_time period_day weekday_weekend
## 1           1         Bread 2016-10-30 09:58:00    morning         weekend
## 2           2  Scandinavian 2016-10-30 10:05:00    morning         weekend
## 3           2  Scandinavian 2016-10-30 10:05:00    morning         weekend
## 4           3 Hot chocolate 2016-10-30 10:07:00    morning         weekend
## 5           3           Jam 2016-10-30 10:07:00    morning         weekend
## 6           3       Cookies 2016-10-30 10:07:00    morning         weekend
```

1.2.2. 3.2

```
str(BreadBasket)
```

```
## 'data.frame':    20507 obs. of  5 variables:
##  $ Transaction    : int  1 2 2 3 3 3 4 5 5 5 ...
##  $ Item           : chr  "Bread" "Scandinavian" "Scandinavian" "Hot chocolate" ...
##  $ date_time      : POSIXlt, format: "2016-10-30 09:58:00" "2016-10-30 10:05:00" ...
##  $ period_day     : chr  "morning" "morning" "morning" "morning" ...
##  $ weekday_weekend: chr  "weekend" "weekend" "weekend" "weekend" ...
```

```
head(BreadBasket)
```

```
##   Transaction          Item           date_time period_day weekday_weekend
## 1           1         Bread 2016-10-30 09:58:00    morning         weekend
## 2           2  Scandinavian 2016-10-30 10:05:00    morning         weekend
## 3           2  Scandinavian 2016-10-30 10:05:00    morning         weekend
## 4           3 Hot chocolate 2016-10-30 10:07:00    morning         weekend
## 5           3           Jam 2016-10-30 10:07:00    morning         weekend
## 6           3       Cookies 2016-10-30 10:07:00    morning         weekend
```

```
tail(BreadBasket)
```

```
##       Transaction         Item           date_time period_day weekday_weekend
## 20502        9682 Tacos-Fajita 2017-04-09 14:32:00  afternoon         weekend
## 20503        9682       Coffee 2017-04-09 14:32:00  afternoon         weekend
## 20504        9682          Tea 2017-04-09 14:32:00  afternoon         weekend
## 20505        9683       Coffee 2017-04-09 14:57:00  afternoon         weekend
## 20506        9683       Pastry 2017-04-09 14:57:00  afternoon         weekend
```

```
## 20507        9684    Smoothies 2017-04-09 15:04:00  afternoon         weekend
```

```
summary(BreadBasket)
```

```
##   Transaction       Item             date_time
##  Min.   :   1   Length:20507       Min.   :2016-10-30 09:58:00
##  1st Qu.:2552   Class :character   1st Qu.:2016-12-03 14:28:00
##  Median :5137   Mode  :character   Median :2017-01-22 11:18:00
##  Mean   :4976                      Mean   :2017-01-18 01:25:37
##  3rd Qu.:7357                      3rd Qu.:2017-02-28 16:00:00
##  Max.   :9684                      Max.   :2017-04-09 15:04:00
##   period_day        weekday_weekend
##  Length:20507       Length:20507
##  Class :character   Class :character
##  Mode  :character   Mode  :character
##
##
##
```

1.3. Ejercicio 4 Fichero SPSS PsychBike.sav

1.3.1. 4.1

```
library(haven)

filename <- "data/PsychBike.sav"

PsychBike <- read_sav(filename)

head(PsychBike)
```

```
## # A tibble: 6 x 6
##   vehicle   Colour           hour   helmet Distance_from_kerb Passing_distance
##   <dbl+lbl> <dbl+lbl>        <time>  <dbl>              <dbl>            <dbl>
## 1 1 [car]    1 [blue]        16:00       0                0.5             1.86
## 2 5 [HGV]    2 [red]         16:00       0                0.5             0.748
## 3 2 [LGV]    1 [blue]        16:00       0                0.5             1.57
## 4 1 [car]   99 [unknown]     16:00       0                0.5             1.39
## 5 4 [bus]    9 [other]       16:00       0                0.5             1.29
## 6 1 [car]    3 [silver/grey] 16:00       0                0.5             1.26
```

```
save(
  PsychBike,
  file = "./data/results/PsychBike.Rdata"
)
```

1.3.2. 4.2

```
str(PsychBike)
```

```
## tibble [2,355 x 6] (S3: tbl_df/tbl/data.frame)
##  $ vehicle           : dbl+lbl [1:2355] 1, 5, 2, 1, 4, 1, 2, 1, 4, 7, 2, 3, 1, 1, 1, 2, 1, 2,...
##    ..@ format.spss: chr "F11.0"
##    ..@ labels     : Named num [1:7] 1 2 3 4 5 6 7
##    .. ..- attr(*, "names")= chr [1:7] "car" "LGV" "SUV" "bus" ...
```

```
##  $ Colour            : dbl+lbl [1:2355]  1,  2,  1, 99,  9,  3,  4,  2,  2, 99,  4,  4,  1,  ...
##    ..@ format.spss: chr "F11.0"
##    ..@ labels     : Named num [1:8] 1 2 3 4 5 6 9 99
##    .. ..- attr(*, "names")= chr [1:8] "blue" "red" "silver/grey" "white" ...
##  $ hour              : 'hms' num [1:2355] 16:00:00 16:00:00 16:00:00 16:00:00 ...
##   ..- attr(*, "units")= chr "secs"
##   ..- attr(*, "format.spss")= chr "TIME11.2"
##  $ helmet            : num [1:2355] 0 0 0 0 0 0 1 1 1 1 ...
##   ..- attr(*, "format.spss")= chr "F11.0"
##  $ Distance_from_kerb: num [1:2355] 0.5 0.5 0.5 0.5 0.5 0.5 1 1 1 1 ...
##   ..- attr(*, "label")= chr "Distance from kerb"
##   ..- attr(*, "format.spss")= chr "F11.1"
##  $ Passing_distance  : num [1:2355] 1.864 0.748 1.567 1.39 1.294 ...
##   ..- attr(*, "label")= chr "Passing distance"
##   ..- attr(*, "format.spss")= chr "F11.3"
```

```
head(PsychBike)
```

```
## # A tibble: 6 x 6
##   vehicle   Colour           hour   helmet Distance_from_kerb Passing_distance
##   <dbl+lbl> <dbl+lbl>        <time>  <dbl>               <dbl>            <dbl>
## 1 1 [car]    1 [blue]        16:00       0                 0.5            1.86
## 2 5 [HGV]    2 [red]         16:00       0                 0.5            0.748
## 3 2 [LGV]    1 [blue]        16:00       0                 0.5            1.57
## 4 1 [car]   99 [unknown]     16:00       0                 0.5            1.39
## 5 4 [bus]    9 [other]       16:00       0                 0.5            1.29
## 6 1 [car]    3 [silver/grey] 16:00       0                 0.5            1.26
```

```
tail(PsychBike)
```

```
## # A tibble: 6 x 6
##   vehicle   Colour          hour   helmet Distance_from_kerb Passing_distance
##   <dbl+lbl> <dbl+lbl>       <time>  <dbl>               <dbl>            <dbl>
## 1 2 [LGV]   9 [other]       10:00       1                1.25            1.10
## 2 1 [car]   3 [silver/grey] 10:00       1                1.25            1.01
## 3 1 [car]   2 [red]         10:00       1                1.25            0.922
## 4 5 [HGV]   4 [white]       10:00       1                1.25            0.564
## 5 1 [car]   1 [blue]        10:00       1                1.25            0.65
## 6 1 [car]   6 [green]       10:00       1                1.25            0.781
```

```
summary(PsychBike)
```

```
##     vehicle          Colour           hour              helmet
##  Min.   :1.000   Min.   : 1.000   Length:2355       Min.   :0.0000
##  1st Qu.:1.000   1st Qu.: 1.000   Class1:hms        1st Qu.:0.0000
##  Median :1.000   Median : 3.000   Class2:difftime   Median :0.0000
##  Mean   :1.634   Mean   : 3.556   Mode  :numeric    Mean   :0.4879
##  3rd Qu.:2.000   3rd Qu.: 4.000                     3rd Qu.:1.0000
##  Max.   :7.000   Max.   :99.000                     Max.   :1.0000
##  Distance_from_kerb Passing_distance
##  Min.   :0.2500     Min.   :0.144
##  1st Qu.:0.2500     1st Qu.:1.053
##  Median :0.5000     Median :1.279
##  Mean   :0.6702     Mean   :1.314
##  3rd Qu.:1.0000     3rd Qu.:1.540
##  Max.   :1.2500     Max.   :3.537
```

1.4. Ejercicio 5 Fichero data iris.zip

1.4.1. 5.1

```
url <- "https://archive.ics.uci.edu/static/public/53/iris.zip"
filename <- "data/iris.zip"

download.file(
  url = url,
  destfile = filename,
  mode = "wb"
)
```

```
# Descomprimimos los archivos dentro de data
iris <- unzip(
  zipfile = filename,
  exdir = "data"
)

iris
```

```
## [1] "data/Index"           "data/bezdekIris.data" "data/iris.data"
## [4] "data/iris.names"
```

1.5. Ejercicio 6

1.5.1. 6.1

```
#help(read.table)
iris_data <- read.table(iris[3],sep=",")
head(iris_data)
```

1.5.1.1. 1

```
##    V1  V2  V3  V4          V5
## 1 5.1 3.5 1.4 0.2 Iris-setosa
## 2 4.9 3.0 1.4 0.2 Iris-setosa
## 3 4.7 3.2 1.3 0.2 Iris-setosa
## 4 4.6 3.1 1.5 0.2 Iris-setosa
## 5 5.0 3.6 1.4 0.2 Iris-setosa
## 6 5.4 3.9 1.7 0.4 Iris-setosa
```

```
names(iris_data) <- c("sepal length", "sepal width", "petal length","petal width","class")
names(iris_data)
```

1.5.1.2. 2

```
## [1] "sepal length" "sepal width"  "petal length" "petal width"  "class"
```

```
save(
  iris_data,
  file = "./data/results/iris.RData"
)
```

1.5.1.3. 3

1.5.2. 6.2

```
str(iris_data)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ sepal length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ sepal width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ petal length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ petal width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ class       : chr  "Iris-setosa" "Iris-setosa" "Iris-setosa" "Iris-setosa" ...
```

```
head(iris_data)
```

```
##   sepal length sepal width petal length petal width       class
## 1          5.1         3.5          1.4         0.2 Iris-setosa
## 2          4.9         3.0          1.4         0.2 Iris-setosa
## 3          4.7         3.2          1.3         0.2 Iris-setosa
## 4          4.6         3.1          1.5         0.2 Iris-setosa
## 5          5.0         3.6          1.4         0.2 Iris-setosa
## 6          5.4         3.9          1.7         0.4 Iris-setosa
```

```
tail(iris_data)
```

```
##     sepal length sepal width petal length petal width          class
## 145          6.7         3.3          5.7         2.5 Iris-virginica
## 146          6.7         3.0          5.2         2.3 Iris-virginica
## 147          6.3         2.5          5.0         1.9 Iris-virginica
## 148          6.5         3.0          5.2         2.0 Iris-virginica
## 149          6.2         3.4          5.4         2.3 Iris-virginica
## 150          5.9         3.0          5.1         1.8 Iris-virginica
```

```
summary(iris_data)
```

```
##   sepal length    sepal width     petal length    petal width
##  Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
##  1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
##  Median :5.800   Median :3.000   Median :4.350   Median :1.300
##  Mean   :5.843   Mean   :3.054   Mean   :3.759   Mean   :1.199
##  3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
##  Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
##     class
##  Length:150
##  Class :character
##  Mode  :character
##
##
##
```

Dataset con los nombres cambiados como en la web

1.6. Ejercicio 7

1.6.1. 7.2

```
library(jsonlite)

#help(read_json)
```

```
filename <- "data/FileCodificado.json"


###datosLista <- read_json(
###  filename,
###  simplifyVector = FALSE
###)

FileCodificado <- read_json(
  filename,
  simplifyVector = TRUE
)

str(FileCodificado)
```

```
## 'data.frame':    83 obs. of  22 variables:
##  $ Carburante             : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ Potencia               : int  60 60 60 60 60 60 60 60 60 60 ...
##  $ Servicio_Vehiculo      : chr  "B00" "B00" "B00" "B00" ...
##  $ Actividad_Vehiculo     : chr  "D" "D" "D" "D" ...
##  $ GAMA                   : chr  "UTILITARIO" "UTILITARIO" "UTILITARIO" "UTILITARIO" ...
##  $ Unidades_Matriculadas  : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Localidad_definitiva   : chr  "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" ...
##  $ Provincia_definitiva   : chr  "CADIZ" "CADIZ" "CADIZ" "CADIZ" ...
##  $ Codigo_Postal          : num  0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.029
##  $ Viviendas              : num  0.12 0.12 0.12 0.12 0.12 ...
##  $ precio_medio_m2        : num  0.18 0.18 0.18 0.18 0.18 ...
##  $ Peso_vivienda          : int  2 2 2 2 2 2 2 2 2 2 ...
##  $ RAISON_SOCIAL          : chr  "ALGECIREÑA DE MOTOR E INV., S.L." "ALGECIREÑA DE MOTOR E INV., S.L
##  $ RUE_SSOC               : chr  "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Km. 108" "Ctra. a Malaga
##  $ Edad_Conductor         : chr  "18 a 20 años" "21 a 24 años" "25 a 29 años" "30 a 34 años" ...
##  $ Numero de Conductores  : num  0.0132 0.0569 0.1086 0.1392 0.1706 ...
##  $ Antigüedad             : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Anos_Antiguedad        : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Numero_vehiculos_parque: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Cluster_GamaPotencia   : chr  "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" "cluster_1_GamaPo
##  $ Cluster_Antiguedad     : chr  "cluster_1_Antiguedad" "cluster_1_Antiguedad" "cluster_1_Antiguedad
##  $ Cluster_Edad           : chr  "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad"
```

Sin el simplifyVector te lo imprime sin simplificar devolviendo el dataset entero sin comprimir.

```
save(
  FileCodificado,
  file = "./data/results/FileCodificado.RData"
)
```

1.6.2. 7.3

```
str(FileCodificado)
```

```
## 'data.frame':    83 obs. of  22 variables:
##  $ Carburante             : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ Potencia               : int  60 60 60 60 60 60 60 60 60 60 ...
##  $ Servicio_Vehiculo      : chr  "B00" "B00" "B00" "B00" ...
```

```
##  $ Actividad_Vehiculo     : chr  "D" "D" "D" "D" ...
##  $ GAMA                   : chr  "UTILITARIO" "UTILITARIO" "UTILITARIO" "UTILITARIO" ...
##  $ Unidades_Matriculadas  : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Localidad_definitiva   : chr  "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" ...
##  $ Provincia_definitiva   : chr  "CADIZ" "CADIZ" "CADIZ" "CADIZ" ...
##  $ Codigo_Postal          : num  0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.029
##  $ Viviendas              : num  0.12 0.12 0.12 0.12 0.12 ...
##  $ precio_medio_m2        : num  0.18 0.18 0.18 0.18 0.18 ...
##  $ Peso_vivienda          : int  2 2 2 2 2 2 2 2 2 2 ...
##  $ RAISON_SOCIAL          : chr  "ALGECIREÑA DE MOTOR E INV., S.L." "ALGECIREÑA DE MOTOR E INV., S.L
##  $ RUE_SSOC               : chr  "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Km. 108" "Ctra. a Malaga
##  $ Edad_Conductor         : chr  "18 a 20 años" "21 a 24 años" "25 a 29 años" "30 a 34 años" ...
##  $ Numero de Conductores  : num  0.0132 0.0569 0.1086 0.1392 0.1706 ...
##  $ Antigüedad             : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Anos_Antiguedad        : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Numero_vehiculos_parque: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Cluster_GamaPotencia   : chr  "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" "cluster_1_GamaPo
##  $ Cluster_Antiguedad     : chr  "cluster_1_Antiguedad" "cluster_1_Antiguedad" "cluster_1_Antiguedad
##  $ Cluster_Edad           : chr  "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad"
```

```
head(FileCodificado)
```

```
##   Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA
## 1          1       60               B00                  D UTILITARIO
## 2          1       60               B00                  D UTILITARIO
## 3          1       60               B00                  D UTILITARIO
## 4          1       60               B00                  D UTILITARIO
## 5          1       60               B00                  D UTILITARIO
## 6          1       60               B00                  D UTILITARIO
##   Unidades_Matriculadas Localidad_definitiva Provincia_definitiva Codigo_Postal
## 1                     0           ALGECIRAS                CADIZ        0.0297
## 2                     0           ALGECIRAS                CADIZ        0.0297
## 3                     0           ALGECIRAS                CADIZ        0.0297
## 4                     0           ALGECIRAS                CADIZ        0.0297
## 5                     0           ALGECIRAS                CADIZ        0.0297
## 6                     0           ALGECIRAS                CADIZ        0.0297
##   Viviendas precio_medio_m2 Peso_vivienda                  RAISON_SOCIAL
## 1    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 2    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 3    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 4    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 5    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 6    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
##                  RUE_SSOC Edad_Conductor Numero de Conductores Antigüedad
## 1 Ctra. a Malaga, Km. 108   18 a 20 años               0.0132          0
## 2 Ctra. a Malaga, Km. 108   21 a 24 años               0.0569          0
## 3 Ctra. a Malaga, Km. 108   25 a 29 años               0.1086          0
## 4 Ctra. a Malaga, Km. 108   30 a 34 años               0.1392          0
## 5 Ctra. a Malaga, Km. 108   35 a 39 años               0.1706          0
## 6 Ctra. a Malaga, Km. 108   40 a 44 años               0.1577          0
##   Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia
## 1               0                       0 cluster_1_GamaPotencia
## 2               0                       0 cluster_1_GamaPotencia
## 3               0                       0 cluster_1_GamaPotencia
## 4               0                       0 cluster_1_GamaPotencia
```

```
## 5               0                       0 cluster_1_GamaPotencia
## 6               0                       0 cluster_1_GamaPotencia
##     Cluster_Antiguedad   Cluster_Edad
## 1 cluster_1_Antiguedad cluster_3_Edad
## 2 cluster_1_Antiguedad cluster_3_Edad
## 3 cluster_1_Antiguedad cluster_3_Edad
## 4 cluster_1_Antiguedad cluster_3_Edad
## 5 cluster_1_Antiguedad cluster_3_Edad
## 6 cluster_1_Antiguedad cluster_3_Edad
```

```
tail(FileCodificado)
```

```
##    Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA
## 78          1       60               B00                  D UTILITARIO
## 79          1       60               B00                  D UTILITARIO
## 80          1       60               B00                  D UTILITARIO
## 81          1       60               B00                  D UTILITARIO
## 82          1       60               B00                  D UTILITARIO
## 83          1       60               B00                  D UTILITARIO
##    Unidades_Matriculadas    Localidad_definitiva Provincia_definitiva
## 78                     0 CHICLANA DE LA FRONTERA                CADIZ
## 79                     0 CHICLANA DE LA FRONTERA                CADIZ
## 80                     0 CHICLANA DE LA FRONTERA                CADIZ
## 81                     0 CHICLANA DE LA FRONTERA                CADIZ
## 82                     0 CHICLANA DE LA FRONTERA                CADIZ
## 83                     0 CHICLANA DE LA FRONTERA                CADIZ
##    Codigo_Postal Viviendas precio_medio_m2 Peso_vivienda          RAISON_SOCIAL
## 78         0.028    0.1132          0.4255             3       RAMON HOYO, S.L.
## 79         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 80         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 81         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 82         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 83         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
##                    RUE_SSOC Edad_Conductor Numero de Conductores Antigüedad
## 78 AVDA. REYES CATOLICOS, 5 Más de 74 años                0.0098          0
## 79               Caraza, 33   18 a 20 años                0.0099          0
## 80               Caraza, 33   21 a 24 años                0.0321          0
## 81               Caraza, 33   25 a 29 años                0.0793          0
## 82               Caraza, 33   30 a 34 años                0.0946          0
## 83               Caraza, 33   35 a 39 años                0.1150          0
##    Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia
## 78               0                       0 cluster_1_GamaPotencia
## 79               0                       0 cluster_1_GamaPotencia
## 80               0                       0 cluster_1_GamaPotencia
## 81               0                       0 cluster_1_GamaPotencia
## 82               0                       0 cluster_1_GamaPotencia
## 83               0                       0 cluster_1_GamaPotencia
##     Cluster_Antiguedad   Cluster_Edad
## 78 cluster_6_Antiguedad cluster_3_Edad
## 79 cluster_1_Antiguedad cluster_3_Edad
## 80 cluster_1_Antiguedad cluster_3_Edad
## 81 cluster_1_Antiguedad cluster_3_Edad
## 82 cluster_1_Antiguedad cluster_3_Edad
## 83 cluster_1_Antiguedad cluster_3_Edad
```

```r
summary(FileCodificado)
```

```
##    Carburante    Potencia  Servicio_Vehiculo  Actividad_Vehiculo
##  Min.   :1    Min.   :60   Length:83          Length:83
##  1st Qu.:1    1st Qu.:60   Class :character   Class :character
##  Median :1    Median :60   Mode  :character   Mode  :character
##  Mean   :1    Mean   :60
##  3rd Qu.:1    3rd Qu.:60
##  Max.   :1    Max.   :60
##      GAMA           Unidades_Matriculadas Localidad_definitiva
##  Length:83          Min.   :0             Length:83
##  Class :character   1st Qu.:0             Class :character
##  Mode  :character   Median :0             Mode  :character
##                     Mean   :0
##                     3rd Qu.:0
##                     Max.   :0
##  Provincia_definitiva Codigo_Postal      Viviendas      precio_medio_m2
##  Length:83            Min.   :0.0280   Min.   :0.1132   Min.   :0.1799
##  Class :character     1st Qu.:0.0280   1st Qu.:0.1132   1st Qu.:0.1799
##  Mode  :character     Median :0.0280   Median :0.1132   Median :0.4255
##                       Mean   :0.1003   Mean   :0.1487   Mean   :0.3761
##                       3rd Qu.:0.0297   3rd Qu.:0.1201   3rd Qu.:0.4255
##                       Max.   :0.4860   Max.   :0.3258   Max.   :0.6015
##  Peso_vivienda   RAISON_SOCIAL        RUE_SSOC         Edad_Conductor
##  Min.   :2.000   Length:83          Length:83          Length:83
##  1st Qu.:2.000   Class :character   Class :character   Class :character
##  Median :3.000   Mode  :character   Mode  :character   Mode  :character
##  Mean   :2.843
##  3rd Qu.:3.000
##  Max.   :4.000
##  Numero de Conductores   Antigüedad Anos_Antiguedad Numero_vehiculos_parque
##  Min.   :0.00740       Min.   :0    Min.   :0       Min.   :0
##  1st Qu.:0.02720       1st Qu.:0    1st Qu.:0       1st Qu.:0
##  Median :0.06250       Median :0    Median :0       Median :0
##  Mean   :0.06731       Mean   :0    Mean   :0       Mean   :0
##  3rd Qu.:0.10035       3rd Qu.:0    3rd Qu.:0       3rd Qu.:0
##  Max.   :0.17060       Max.   :0    Max.   :0       Max.   :0
##  Cluster_GamaPotencia Cluster_Antiguedad Cluster_Edad
##  Length:83            Length:83          Length:83
##  Class :character     Class :character   Class :character
##  Mode  :character     Mode  :character   Mode  :character
##
##
##
```

Vemos como la mayoria de las varibles son char, expecto carburante,unidades y Peso_vivienda que son ints y codigo_postal y viviendas que son double. ## Ejercicio 8 Fichero JSON

```r
filename <- "data/iris_json.json"

iris_json <- read_json(
  filename,
  simplifyVector = TRUE
)
```

```
#help(fromJSON)

iris_json_2 <- fromJSON(
  filename,
  simplifyVector = TRUE
)


head(iris_json)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
## 4          4.6         3.1          1.5         0.2  setosa
## 5          5.0         3.6          1.4         0.2  setosa
## 6          5.4         3.9          1.7         0.4  setosa
```

```
head(iris_json_2)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
## 4          4.6         3.1          1.5         0.2  setosa
## 5          5.0         3.6          1.4         0.2  setosa
## 6          5.4         3.9          1.7         0.4  setosa
```

```
save(
  iris_json,
  file = "./data/results/iris_json.RData"
)
```

1.6.2.1. 4

1.6.3. 8.2

```
str(iris_json)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ Species     : chr  "setosa" "setosa" "setosa" "setosa" ...
```

```
head(iris_json)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
## 4          4.6         3.1          1.5         0.2  setosa
## 5          5.0         3.6          1.4         0.2  setosa
## 6          5.4         3.9          1.7         0.4  setosa
```

```r
tail(iris_json)
```

```
##     Sepal.Length Sepal.Width Petal.Length Petal.Width   Species
## 145          6.7         3.3          5.7         2.5 virginica
## 146          6.7         3.0          5.2         2.3 virginica
## 147          6.3         2.5          5.0         1.9 virginica
## 148          6.5         3.0          5.2         2.0 virginica
## 149          6.2         3.4          5.4         2.3 virginica
## 150          5.9         3.0          5.1         1.8 virginica
```

```r
summary(iris_json)
```

```
##   Sepal.Length    Sepal.Width     Petal.Length    Petal.Width
##  Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
##  1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
##  Median :5.800   Median :3.000   Median :4.350   Median :1.300
##  Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
##  3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
##  Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
##    Species
##  Length:150
##  Class :character
##  Mode  :character
##
##
##
```

Vemos que estos datos son los mismos que los de el dataset anterior de Iris.

1.6.4. 8.3

1.6.4.1. 1 Cargo Rdata y escribo el json

```r
filename <- 'data/iris_json_v2.json'

load("./data/results/iris.RData")

write_json(
  iris_data,
  path = filename,
  pretty = TRUE
)
```

```r

filename <- "data/iris_json_v3.json"

irisJSON <- toJSON(iris_data, pretty = TRUE)

write_file(irisJSON, file = filename)
```

```r

# Formato compacto
cat(toJSON(head(iris_data), pretty = FALSE))
```

1.6.4.2. 2

```
## [{"sepal length":5.1,"sepal width":3.5,"petal length":1.4,"petal width":0.2,"class":"Iris-setosa"},{
```

```r
# Formato con saltos de línea y sangrías
cat(toJSON(head(iris_data), pretty = TRUE))
```

```
## [
##   {
##     "sepal length": 5.1,
##     "sepal width": 3.5,
##     "petal length": 1.4,
##     "petal width": 0.2,
##     "class": "Iris-setosa"
##   },
##   {
##     "sepal length": 4.9,
##     "sepal width": 3,
##     "petal length": 1.4,
##     "petal width": 0.2,
##     "class": "Iris-setosa"
##   },
##   {
##     "sepal length": 4.7,
##     "sepal width": 3.2,
##     "petal length": 1.3,
##     "petal width": 0.2,
##     "class": "Iris-setosa"
##   },
##   {
##     "sepal length": 4.6,
##     "sepal width": 3.1,
##     "petal length": 1.5,
##     "petal width": 0.2,
##     "class": "Iris-setosa"
##   },
##   {
##     "sepal length": 5,
##     "sepal width": 3.6,
##     "petal length": 1.4,
##     "petal width": 0.2,
##     "class": "Iris-setosa"
##   },
##   {
##     "sepal length": 5.4,
##     "sepal width": 3.9,
##     "petal length": 1.7,
##     "petal width": 0.4,
##     "class": "Iris-setosa"
##   }
## ]
```

Con el parametro Prety controlas si añadir saltos de línea y sangrías para ser mas facil de ver y entender.